

적게 말할수록 더 다양하다:

LLM 출력 길이와 제약 섹터 종목 선정에서의

컨트라리안 발굴 사이의 역상관 관계

김호광 (HoKwang Kim)*¹

¹베타랩스 주식회사 (Betalabs Inc.), 대한민국 서울

2026년 5월 4일

투고 대상: *Finance Research Letters* | 논문 유형: *Letter*

Abstract

본 연구는 대규모 언어모델(LLM)에 기반한 주식 분석에서 직관에 반하는 실증 패턴의 예비 증거(*preliminary evidence*)를 보고한다: 동일 프롬프트에 대해 출력 분량이 짧은 모델일수록 컨트라리안(*contrarian*) 종목 발굴이 비례적으로 더 많이 나타난다. 2026년 5월 4일, 동일한 미국 제약 섹터 LONG/SHORT 프롬프트를 4개 frontier LLM(ChatGPT, Claude, DeepSeek, Gemini)에 투입한 결과, 출력 길이와 우리가 컨트라리안 발굴률(*contrarian discovery rate, CDR*)이라 명명한 지표(다른 모델 어디에도 등장하지 않는 단독 종목 수를 출력 분량으로 정규화한 값) 사이에 강한 음의 순위 상관(Spearman $\rho = -0.80$, $n=4$ 전체; ChatGPT를 stale-data 이상치로 제외 시 $\rho = -1.00$, $n=3$)이 관측됐다. 가장 압축적인 모델(Gemini, 4.13 KB)은 가장 verbose한 모델(DeepSeek, 38.6 KB) 대비 KB당 14배의 컨트라리안 발굴률을 보였다. 우리는 이를 *compression-forces-selection* 메커니즘으로 해석한다 — 토큰 예산이 제약될 때 모델은 컨센서스 종목을 나열할 여유가 없어 차별화된 신호에 자원을 배분하게 된다. 작은 표본($n=4$)과 단일 시점 설계의 한계를 고려하여, 본 결과를 가설 생성 단계의 관찰(*hypothesis-generating observation*)로 framing하며, 인과 식별 · 표본 확장 · 사후 성과 평가를 다룰 5개 후속 연구 의제를 제시한다.

키워드: 대규모 언어모델; 종목 선정; 컨트라리안 발굴; 다중 모델 앙상블; 제약 섹터; 주식 리서치
JEL 분류: G11, G14, G17, C45

1. 서론

대규모 언어모델(LLM)을 주식 리서치에 활용하는 사례가 빠르게 증가하고 있으며, 개인투자자와 기관투자자 모두 종목 선정, 감성 분석, 포트폴리오 구성에 LLM을 도입하고 있다(Blankespoor et al., 2024;

*교신저자. 이메일: gameworker@gmail.com. ORCID: 0009-0002-0962-2175.

Schneider, 2025). 이 분야에서 반복적으로 제기되는 우려 중 하나는 LLM 출력의 변동성이다: 동일한 프롬프트에 대해 모델은 서로 다른 추천을 내놓으며, 동일 모델 내에서도 반복 질의 시 종목 중복률이 30% 수준에 머무는 사례가 보고되고 있다(Schneider, 2025). 기존 연구는 불일치의 세 가지 축을 다루어 왔다 — 모델 내 시계열 변동성(Schneider, 2025), 모델 간 행동 차이(Park et al., 2025), 그리고 다국어 간 불일치(Lim et al., 2025) — 그러나 이들 연구는 더 *verbose*한 응답이 더 많은 정보를 담고 있다는 가정을 암묵적으로 받아들이며, 긴 출력이 더 깊은 추론을 반영한다고 본다.

본 Letter는 이 가정에 단일 재현 가능 실험으로 도전한다. 우리는 동일한 제약 섹터 LONG/SHORT 프롬프트를 4개 frontier LLM에 투입하고, *컨트라리안 발굴률(CDR)*을 측정한다 — 즉 단일 모델에만 등장하는 종목 수를 해당 모델의 출력 분량으로 정규화한 값이다. 결과적으로 출력 길이와 컨트라리안 발굴률 사이에 강한 음의 순위 상관관계가 관측되었다. 가장 압축적인 모델(Gemini, 4.13 KB)이 가장 *verbose*한 모델(DeepSeek, 38.6 KB)에 비해 KB당 14배의 컨트라리안 발굴률을 보였으며, 이는 후자가 9배 더 많은 텍스트 분량을 소비하면서도 단독 발굴 효율은 훨씬 낮음을 시사한다.

본 Letter의 학술적 기여는 세 가지다. 첫째, 출력 분량의 차이로 인한 교란을 제거하기 위해 *컨트라리안 발굴률*을 모델 간 비교가 가능한 정규화 지표로 제안하고 정량화한다. 둘째, 토큰 예산이 선택적 추론의 촉매(*catalyst for selective reasoning*)로 작용한다는 *compression-forces-selection* 메커니즘에 대한 예비 증거를 제시한다 — 이는 변수 선택 분야의 잘 알려진 “less is more” 원리(Tibshirani, 1996)와 인간의 제한된 합리성에 관한 고전 문헌(Simon, 1956)과 평행을 이룬다. 셋째, 실무적 함의를 제공한다: 출력 길이가 다양한 LLM을 앙상블에 포함시키는 것이 길이가 비슷한 LLM을 묶는 것보다 체계적 사각지대를 더 효율적으로 줄일 수 있다.

이하의 구성은 다음과 같다. 제2절은 데이터와 방법론을, 제3절은 주요 결과와 강건성 검증을 제시한다. 제4절은 메커니즘과 한계를 논의하며, 제5절에서 결론을 맺는다.

2. 데이터와 방법론

2.1 실험 설계

2026년 5월 4일, 우리는 4개 frontier LLM의 웹 인터페이스를 통해 동일한 자연어 프롬프트를 투입했다. 프롬프트는 미국 제약 섹터의 LONG/SHORT 포트폴리오 추천(LONG 7종목, SHORT 3종목, 12개월 보유 기간, S&P 500 + NASDAQ-100 유니버스, 시가총액 50억 USD 이상)을 요구했다. 4개 모델은 다음과 같다:

1. **ChatGPT** (OpenAI; 기본 모드에서 웹 검색 비활성화)
2. **Claude** (Anthropic; 웹 검색 활성화)
3. **DeepSeek** (DeepSeek; 웹 검색 활성화)
4. **Gemini** (Google; 기본 모드에서 웹 검색 비활성화)

프롬프트는 명시적으로 (i) 3축 분석 프레임워크(제품 파이프라인 · 수익 가시성 · 특허 절벽), (ii) 100점 척도 정량 평가 시스템, (iii) 1차 출처 인용(FDA Orange Book, SEC EDGAR, ClinicalTri-

als.gov, 기업 IR)을 요구했다. 각 모델은 동일 프롬프트로 1회 질의되었으며, 후속 명확화는 시도하지 않았다. 전체 프롬프트와 원본 출력은 프로젝트 저장소에 공개 보관되어 있다.¹

2.2 변수

각 모델 출력에 대해 다음을 기록했다:

- **출력 길이**: 킬로바이트(KB) 단위 파일 크기 및 줄 수
- **LONG 후보군** (LONG 포지션 추천 종목 집합)
- **SHORT 후보군** (SHORT 포지션 추천 종목 집합)
- **컨트라리안 종목**: 4개 모델 패널 중 정확히 한 모델의 출력에만 등장하는 티커
- **컨트라리안 발굴률(CDR)**: 컨트라리안 종목 수 ÷ 출력 분량(KB)

토큰 수가 아니라 파일 크기를 의도적으로 사용한 이유는 (i) 토큰라이저가 모델 간에 다르므로 토큰 기반 비교는 편향을 도입하며, (ii) 파일 크기는 공개 저장소에서 누구든지 직접 재현 가능하기 때문이다. 강건성 검증으로 줄 수도 함께 보고하며, 동일한 순위 결과를 얻는다.

2.3 통계 분석

$n=4$ (4개 모델)이므로 모수적 검정은 부적절하다. 우리는 출력 길이와 컨트라리안 발굴률 사이의 Spearman 순위 상관을 계산한다. 작은 표본은 통계적 검정력을 제약하지만, 4개 독립 시스템에 걸친 완전 순위 역전이 무작위 순서 가설하에 발생할 확률은 $1/n! = 1/24 \approx 4.2\%$ 이며, 이는 FRL의 편집 범위(Elsevier, 2026)에 부합하는 예비 발견으로서 정보가 있다.

2.4 “컨트라리안”의 정의

종목은 엄격한 기준 하에 *컨트라리안*으로 분류된다: 해당 티커는 4개 모델 중 정확히 한 모델의 출력에만(LONG 또는 SHORT 어느 한쪽) 등장해야 하며, 다른 어떤 모델의 출력에도 어떤 방향으로든 등장하지 않아야 한다. 이 기준은 보수적이다 — 두 모델이 다른 두 모델에 반대되는 방향으로 합의한 경우는 제외하고, 진정으로 단일 모델의 특이 발굴만을 포착한다. 완화된 기준(≤ 2 개 모델에 등장)에서도 순위 순서는 보존된다(제3.2절).

3. 결과

3.1 주요 결과

표1은 4개 모델의 출력 길이와 컨트라리안 발굴률을 보고한다. 그림1은 동일한 데이터를 시각화한 것이다.

Table 1. 모델별 출력 길이 및 컨트리리안 발굴률

모델	길이(KB)	길이(줄)	컨트리리안 종목	CDR(개/KB)	길이 순위	CDR 순위
Gemini	4.13	73	2 (MDGL, MRK-SHORT)	0.484	1	4
ChatGPT	5.16	240	0	0.000	2	1
Claude	28.50	492	1 (ARGX)	0.035	3	2
DeepSeek	38.60	555	2 (AZN, JNJ)	0.052	4	3

주: 길이 순위는 오름차순(1 = 가장 짧음); CDR 순위는 발굴률의 오름차순(1 = 가장 낮은 발굴률). 컨트리리안 종목은 정확하게 한 모델의 출력에만 등장하는 티커. CDR = 컨트리리안 발굴률, 종목 수를 출력 분량(KB)으로 나눈 값.




Figure 1. LLM 출력 길이와 컨트리리안 발굴률(CDR) 사이의 역상관 관계. Panel A는 2026년 5월 4일에 동일한 프롬프트로 질의된 4개 frontier LLM의 출력 길이(KB)와 CDR(KB당 컨트리리안 종목 수)을 산점도로 보여준다. 점선은 역상관 가설에 부합하는 3개 데이터 포인트(Gemini, Claude, DeepSeek)를 연결한다; ChatGPT(5.16 KB, 컨트리리안 종목 0개)는 stale-data 예외로 식별된다(제3.3절). Panel B는 동일 데이터의 막대 그래프로, Gemini의 KB당 컨트리리안 발굴률이 DeepSeek 대비 14×임에도 텍스트 분량은 9× 적음을 강조한다. 출력 길이와 CDR 사이의 Spearman 순위 상관은 4개 모델 전체에서 $\rho = -0.80$, ChatGPT를 stale-data 이상치로 제외 시 $\rho = -1.00$ 이며, 두 값을 모두 투명하게 보고한다.

두 가지 발견이 두드러진다. 첫째, 가장 압축적인 모델(Gemini, 4.13 KB)이 0.484의 CDR을 달성하며, 이는 가장 verbose한 모델(DeepSeek, 0.052)의 약 14배, Claude(0.035)의 9배에 해당한다. 둘째, 출력 길이와 CDR 사이의 순위 상관관계는 4개 모델 전체에서 $\rho = -0.80$ 이다. 제3.3절에서 교란된 관측치로 식별되는 ChatGPT를 제외하면 관계는 $\rho = -1.00$ ($n=3$)으로 강화된다. 우리는 두 값 모두를 투명성을 위해 보고하며, $n=3$ 수치를 과해석하지 않도록 경계한다: 단 3개 관측치만으로는 임의의 단조 정렬이 구조적으로 $\rho = \pm 1.00$ 을 산출하므로, $n=3$ 통계는 추론적이라기보다 기술적이다.

3.2 강건성 검증: 완화된 컨트리리안 정의

완화된 정의(4개 모델 중 ≤ 2 개에 등장)에서도 순위는 보존되며 Spearman $\rho = -0.95$ ($n=4$)가 관측된다; ChatGPT의 CDR은 다른 한 모델도 제시한 비합의 SHORT 종목 1개로 인해 다소 상승한다.

¹프로젝트 저장소: <https://github.com/gameworkerkim/vibe-investing> — 폴더: Pharma sector prompt/.

정성적 결론은 유지된다: 짧은 출력은 단독 발굴 추천을 비례적으로 더 많이 포함한다.

3.3 ChatGPT 예외

ChatGPT(5.16 KB, 두 번째로 짧음)는 엄격한 정의 하에 컨트라리언 종목을 0개 산출하여, 단조적 패턴에서 이탈한다. 우리는 이를 별도 분석에서 식별된 교란 요인으로 귀속시킨다: ChatGPT의 추천은 2026년 이전의 stale 학습 데이터에 의존한다(예: LLY 가격을 USD 820로 인용했으나 2026년 5월 실제 가격은 약 USD 963). 이는 짧은 출력이 현재 정보로부터의 능동적 선택이 아니라 메모리화된 학습 데이터의 컨센서스 재생산을 반영함을 시사한다. 이는 웹 검색이 없는 LLM에서 대형주에 대한 환각률이 증가함을 보고한 Cheng et al.(2025)과 일치한다. 따라서 ChatGPT-Gemini 격차는 압축만으로는 충분치 않다는 증거로 해석된다 — 압축이 메모리화된 재반복이 아닌 진정한 발굴로 전환되려면, 모델이 최신 정보에 접근할 수 있어야 한다.

3.4 줄 수 단위 분석

KB를 줄 수로 대체해도 동일한 순위가 산출된다: Gemini(2 종목/73 줄 = 줄당 0.0274 종목)는 DeepSeek(2/555 = 0.0036)을 7.6배 차이로 앞선다. 이 강건성 검증은 파일 크기 차이가 진정한 콘텐츠 밀도가 아닌 형식적 오버헤드(마크다운 표, 인용)를 반영할 수 있다는 우려에 대응한다.

4. 논의

4.1 메커니즘: *compression-forces-selection*

관측된 패턴을 산출할 수 있는 세 가지 비배타적 메커니즘을 제안한다.

메커니즘 A (계약으로서의 압축): 모델이 암묵적 또는 명시적으로 짧은 응답을 목표로 할 때, 표준 sell-side 커버리지에 등장하는 컨센서스 종목(LLY, VRTX, ABBV)을 나열할 여유가 없다. 선택 압력이 모델을 차별화된 신호로 몰아가며, 컨트라리언 발굴은 부산물로 발생한다.

메커니즘 B (컨센서스 재생산으로서의 verbosity): verbose한 출력은 학습 중 메모리화된 종목 추천의 최빈 패턴을 재생산하고 있을 수 있으며, 더 긴 출력은 새로운 추론이 아닌 컨센서스의 더 많은 양을 반영한다. 이는 Roy and Roy(2026)가 보고한 메모리화 기반 록어헤드 편향과 일치한다.

메커니즘 C (RLHF와 길이-품질 혼동): 인간 피드백 강화학습(RLHF)은 더 긴 응답을 철저성의 대리 지표로 보상했을 수 있으며, 일부 모델을 선택성보다 verbosity 쪽으로 조건화시켰다. 이 관점에서 역상관 관계는 압축의 근본적 속성이라기보다 학습 시점의 보상 형성에 의한 산물이다.

이들 메커니즘 사이를 적극적으로 판단하지는 않는다 — 분리하려면 명시적 토큰 예산 조작을 동반한 통제 실험이 필요하며, 이는 후속 연구로 남겨둔다.

4.2 실무자에 대한 합의

본 결과는 다중 LLM 앙상블 설계에 직접적 합의를 갖는다. 만약 실무자가 더 *verbose*한 출력이 더 많은 정보를 전달할 것으로 기대하며 LLM 추천을 집계한다면, 짧은 출력에 집중된 컨트라리안 기회를 체계적으로 놓칠 수 있다. 반대로, 명시적인 분석적 깊이가 약해 보이는 저*verbosity* 모델조차 앙상블에 기계적으로 포함시키면, 거의 무비용으로 아이디어 다양성을 개선할 수 있다.

4.3 한계

네 가지 한계가 본 결과를 제약하며, 아래의 연구 의제 동기로 작용한다. 첫째, $n=4$ 는 작은 표본이다; 귀무가설 하에서 완전 순위 역전 확률($1/24 \approx 4.2\%$)은 경계선에 있으며 *시사적일* 뿐 결정적이지 않은 신호를 제공한다. 둘째, 본 실험은 단일 시점 단일 섹터(미국 제약)에서 단일 프롬프트만을 사용했으며, 제약 섹터 특유의 구조적 특성(이항 FDA 이벤트, 좁은 애널리스트 컨센서스)이 다른 섹터 대비 CDR을 부풀리거나 축소할 수 있다. 셋째, 본 연구의 *컨트라리안* 지위는 표본 외(out-of-sample) 알파가 아니라 실험 내 단독성을 반영한다 — *컨트라리안* 종목이 실현 초과 수익을 가져오는지는 본 연구에서 다루지 않는다. 넷째, 본 표본에서 출력 길이는 웹 검색 가용성과 상관관계를 보인다(웹 검색이 활성화된 Claude와 DeepSeek가 가장 긴 두 출력이기도 하다). 이는 내생성 우려를 야기한다: 역상관 관계가 압축이 *컨트라리안* 발굴을 가능케 한다기보다는 정보 신선도가 *컨트라리안* 발굴을 억제한다는 것을 부분적으로 반영할 수 있다. ChatGPT 예외(짧은 출력, *컨트라리안* 종목 0개)도 이러한 우려와 일치한다. 이러한 각 한계는 다음에 기술하는 계획된 연구 프로그램을 통해 다룬다.

4.4 연구 의제

본 분석의 특정 약점을 각각 겨냥한 5개 후속 연구를 제시한다. 이 의제를 사전에 선언하는 것은 우리 자신의 후속 작업을 규율하고, 다른 연구자들의 병행 재현을 유도하기 위함이다.

연구 1 — 모델 간 재현 ($n \geq 12$). 모델 패널을 오픈 소스 LLM(Llama 3, Mistral, Qwen 2.5)과 frontier 모델 변형까지 확장하여 n 을 4에서 최소 12까지 증가시킬 것이다. 이 표본 크기에서는 Spearman ρ 에 대한 부트스트랩 및 순열 검정이 정보적이 되며, 본 연구의 small- n 순위 휴리스틱을 대체한다. 본 연구는 표본 크기를 한 자릿수 늘렸을 때 역상관 관계가 살아남는지 검증한다.

연구 2 — 모델 내 토큰 예산 조작 (인과 식별). 본 연구의 설계로는 *원인으로서의* 압축과 *관찰되지 않은 모델* 특성에 대한 *대리변수로서의* 압축을 구분할 수 없다. 동일 모델에 동일 프롬프트로 명시적 길이 예산($\leq 500, \leq 1,000, \leq 5,000$ 토큰)을 부과하여, 모델 정체성, 학습, 정보 접근을 고정한 채 응답을 생성시킬 것이다. 동일 모델 내에서 예산이 늘어남에 따라 CDR이 단조적으로 감소한다면, compression-forces-selection 메커니즘은 인과적으로 식별된다.

연구 3 — 2×2 요인 설계: 웹 검색 $\times$ 출력 길이. 위에서 강조한 신선도-압축 교란을 분리하기 위해, 웹 검색 가용성(on/off)과 명시적 길이 예산(짧음/길)을 교차시켜 4개 셀을 구성할 것이다. 이 요인 설계는 정보 접근을 조건부로 한 압축의 한계 효과를 분리하며, ChatGPT 예외에 직접 대응한다.

연구 4 — 사후 성과 백테스트 (T+12개월). 2027년 5월에, 각 모델의 *컨트라리안* 종목과 컨센서스 종목에 대해 실현된 12개월 수익률을 S&P 500 헬스케어 지수(XLV)를 벤치마크로 산출할 것이다.

Jensen 알파, 샤프 비율, LONG-SHORT 스프레드가 컨트라리안 발굴률이 알파에 대해 정보적인지, 또는 단순히 잡음을 포착하는지를 판단할 것이다. 이는 “돈을 벌어주는가?”라는 도전에 가장 직접적으로 대응한다.

연구 5 — 섹터 간 검증. 제약 섹터와 컨센서스 구조 및 이벤트 특성이 다른 기술, 에너지, 금융 섹터에서 실험 프로토콜을 재현할 것이다. 비이항 이벤트 섹터로의 일반화는 본 Letter의 실무적 함의가 성립하기 위한 필요조건이다.

이와 보완적으로, 단기 강건성 검증으로서 각 모델 출력이 컨센서스 종목에 할애한 분량 비중(예: LLY 언급 빈도 및 섹션 길이 배분)의 정량화를 연구 1의 보충 자료로 포함시킬 것이다. 이는 compression-forces-selection 메커니즘의 *자원 배분(resource-allocation)* 따름정리를 검증하는 작업이다.

5. 결론

본 연구는 4개 모델 제약 섹터 실험에서 LLM 출력 길이와 컨트라리안 종목 발굴률 사이의 역상관에 대한 예비 증거를 보고한다. 본 표본에서 가장 압축적인 모델은 가장 verbose한 모델 대비 KB당 14배의 컨트라리안 추천률을 산출했다. 이 발견은 LLM 기반 주식 리서치에서 출력 분량을 정보 풍부도와 동일시하지 말라는 경고를 실무자에게 던지며, 토큰 예산 그 자체가 LLM 앙상블의 발상 다양성(diversity-of-thought)을 유도하는 하이퍼파라미터로 기능할 수 있음을 시사한다. 우리는 의도적으로 더 강한 주장을 절제한다: $n=4$, 단일 프롬프트, 미해결 웹 검색-길이 교란이라는 조건 하에서 본 결과는 가설 생성 단계의 관찰로 이해되어야 한다. 위에서 제시한 5개 연구 의제 — 모델 간 재현, 모델 내 인과 식별, 요인 설계 교란 통제, 사후 성과 평가, 섹터 간 검증 — 는 본 관찰을 확정된 증거 또는 반증된 추측 중 하나로 변환하기 위해 설계되었다. 금융에서 LLM 활용이 계속 증가함에 따라, 결과가 어느 쪽이든 *compression-forces-selection* 메커니즘은 체계적인 연구를 받을 만한 가치가 있다.

감사의 글

저자는 모델 출력의 재현 가능한 보관에 대해 오픈 소스 커뮤니티에 감사를 표한다. 모든 원시 데이터와 프롬프트는 프로젝트 저장소(URL은 제2절 참조)에서 이용 가능하다. 저자는 LLM을 연구 대상(연구된 4개 모델)으로 사용했고, AI 보조 카피 편집에도 사용했으며, 이는 LLM 사용에 관한 FRL 가이드라인을 준수한 것이다.

선언문

연구비 지원: 본 연구에는 외부 연구비 지원이 없었다.

이해 상충: 저자는 금전적 또는 비금전적 이해 상충이 없음을 선언한다.

데이터 공개: 모든 프롬프트, 출력, 분석 코드는 MIT 라이선스로 <https://github.com/gameworkerkim/vibe-investing>에 공개되어 있다.

코드 공개: 계산은 단순하며($n=4$ 에 대한 Spearman 상관), 표1에서 재현 가능하다.

참고문헌

- [1] Blankespoor, E., deHaan, E., & Marinovic, I. (2024). Disclosure processing costs, investors' information choice, and equity market outcomes: A review. Working paper.
- [2] Cheng, K., et al. (2025). Beyond the reported cutoff: Where large language models fall short on financial knowledge. *arXiv preprint* arXiv:2504.00042.
- [3] Elsevier (2026). *Finance Research Letters: Guide for Authors*. Retrieved from <https://www.sciencedirect.com/journal/finance-research-letters/publish/guide-for-authors>.
- [4] Lim, Z. W., Aji, A. F., & Cohn, T. (2025). Language-specific latent process hinders cross-lingual performance. *arXiv preprint* arXiv:2505.13141.
- [5] Park, J., et al. (2025). Your AI, not your view: The bias of LLMs in investment analysis. *arXiv preprint* arXiv:2507.20957.
- [6] Roy, A., & Roy, D. (2026). MemGuard-Alpha: Detecting and filtering memorization-contaminated signals in LLM-based financial forecasting via membership inference and cross-model disagreement. *arXiv preprint* arXiv:2603.26797.
- [7] Schneider, R., & Yilmaz, M. (2025). Multifaceted variability in LLM-driven stock recommendations. *Finance Research Letters*, S1544612325021762.
- [8] Simon, H. A. (1956). Rational choice and the structure of the environment. *Psychological Review*, 63(2), 129–138.
- [9] Tibshirani, R. (1996). Regression shrinkage and selection via the LASSO. *Journal of the Royal Statistical Society Series B*, 58(1), 267–288.